

Interval de predicció del retard en una companyia aèria

Grau en Estadística Aplicada

Andy Vacas Garcia | 1600304

Tutor: Antonio Lozano Bages

23 de Juny del 2025



Contents


- 1 Introducció
- 2 Context
- 3 Anàlisi Exploratori de les dades (I)
Anàlisi Exploratori de les dades (II)
- 4 Metodologia
Regressió logística
XGBoost i Gradient Boosting Machines (GBM)
Ensemble i modelització
Mètriques
Intervals de confiança vs predicció i fiabilitat
- 5 Resultats
Comparacions
Fiabilitat
Casos hipotètics
- 6 Conclusió
- 7 Proposta i qüestionari

Introducció

Airlines

- 8 variables i la variable d'interès *Delay*.
- 539383 vols registrats.
- 18 aerolínies.
- 293 aeroports de EE.UU.

- Identificador
- Aerolínia
- Número de vol
- Aeroport de sortida
- Aeroport d'arribada
- Dia de la setmana
- Durada del vol en minuts
- Distància
- Retard







Polítiques en els retards dels EE.UU.

-  Reubicació en un vol de la mateixa aerolínia.
-  No sempre ofereixen reubicació amb altres aerolínies.
-  Vals de menjar si el retard supera les 3 hores.
-  Allotjament gratuït i transport a l'hotel si fes falta passar la nit.
-  No compensació monetària directa.
-  Algunes aerolínies poden oferir crèdits de viatge o milles.

Política de Southwest Airlines


-  Reubicació automàtica o canvi del vol gratuït.
-  Seguiment del vol a la web o app.
-  Crèdit de vol (Transferible Flight Credit ®)
Reemborsament complet si el canvi es superior a:
 - 3 hores (nacionals).
 - 6 hores (internacionals).
-  Avís als passatgers en menys de 30 minuts.

Anàlisi Exploratori de les dades (I)



Anàlisi Exploratori de les dades (II)

Retard i no retard per cada aerolínia



Southwest Airlines (WN)

- 94097 registres.
- 65657 vols amb retard i 28440 sense.
- 84972 amb distàncies de 0 a 200km i 9125 de 200 a 400km.
- 16118 registrats en dimecres i dijous, mentre que dissabte hi han 9791 vols.

TÈCNIQUES UTILITZADES PER ESCOLLIR EL MILLOR MODEL

MODELS PREDICTIUS

- Regressió logística (GLM)
- XGBoost
- Gradient Boosting Machines (GBM)

MODELATGE

- Validació creuada
- Bootstrap amb reemplaçament
- Ensemble

AVALUACIÓ DE MODELS


- Precisió
- Sensibilitat
- Especificitat
- F1-Score

Regressió logística

Regressió logística (GLM)

- La regressió logística modela la probabilitat que el resultat sigui 1.
- Per evitar probabilitats fora del rang $[0, 1]$, s'utilitza la funció logit, que transforma probabilitats a la recta real.


$$\text{logit}(x) = \log\left(\frac{x}{1-x}\right)$$



XGBoost i Gradient Boosting Machines (GBM)

XGBoost

XGBoost és una biblioteca optimitzada que implementa el mètode de boosting de gradient, però amb millores de rendiment, eficiència i flexibilitat.




GBM amb Adaboost

AdaBoost dins de la tècnica Gradient Boosting (GBM) per millorar el rendiment i obtenir prediccions més robustes en la classificació.



Ensemble i modelització



Mètriques

Mètriques

Real \ Predicció	Retard	No retard
	Retard	No retard
No retard	FP	VN
Retard	VP	FN

$$Precisi = \frac{\text{Classificació correcta}}{\text{Totes les classificacions}} = \frac{VP+VN}{VP+FP+VN+FN}$$


$$Sensibilitat = \frac{VP}{VP+FP}$$

$$Especificitat = \frac{VN}{VN+FN}$$

$$F1 - Score = 2 \cdot \frac{Accuracy \cdot Sensibilitat}{Accuracy + Sensibilitat}$$

Intervals de confiança vs predicció i fiabilitat

Interval de confiança vs predicció



- L'interval de confiança : Es centra a l'estimació de l'efecte mig poblacional.
- L'interval de predicció :S'utilitza per anticipar la variabilitat dels efectes en estudis individuals .

Alternatives per variables categòriques

- En lloc d'interval de predicció s'utilitzen probabilitats de classificació en models, tal com regressió logística o arbres de decisió.
- Es poden calcular intervals de confiança per proporcions de cada categoria en una mostra.

Fiabilitat

	CONFIABLE	INCERT
RETARD	PREDICCIÓ >0.50 LIMIT INFERIOR >0.50	PREDICCIÓ >0.50 LIMIT INFERIOR <0.50
NO RETARD	PREDICCIÓ <0.50 LIMIT INFERIOR <0.50	PREDICCIÓ < 0.50 LIMIT INFERIOR >0.50

Resultats


Comparació dels models

Model	Precisió	Sensibilitat	Especificitat	F1
Regresió logística	0.72	0.93	0.25	0.81
XGBoosting	0.72	0.92	0.28	0.81
Gradient Boosting Machines	0.73	0.92	0.28	0.81

Comparació entre predicció del model logístic, realitat i fiabilitat

Grup	Predicció	Real	n
Confiable	No_retard	No_retard	1217
Confiable	No_retard	Retard	719
Confiable	Retard	No_retard	3976
Confiable	Retard	Retard	11939
Incert	No_retard	No_retard	228
Incert	No_retard	Retard	221
Incert	Retard	No_retard	267
Incert	Retard	Retard	252

Fiabilitat



Casos hipotètics

Situació real

AirportFrom	AirportTo	DayOfWeek	Time	Length
LAS	MDW	1	800.00	100.00
PHX	HOU	5	1100.00	150.00
BWI	DEN	7	1500.00	300.00
OAK	SAN	3	100.00	85.00
OAK	SAN	3	90.00	85.00
LAS	MDW	1	215.00	100.00

Predicció

AirportFrom	AirportTo	DayOfWeek	Time	Length	Media	Lower	Upper	Decision
LAS	MDW	1	800.00	100.00	0.78	0.77	0.78	Retard (confiable)
PHX	HOU	5	1100.00	150.00	0.86	0.85	0.86	Retard (confiable)
BWI	DEN	7	1500.00	300.00	0.96	0.96	0.96	Retard (confiable)
OAK	SAN	3	100.00	85.00	0.51	0.50	0.53	Retard (incert)
OAK	SAN	3	90.00	85.00	0.51	0.49	0.52	Retard (incert)
LAS	MDW	1	215.00	100.00	0.45	0.44	0.46	No_retard (confiable)

Conclusió

Conclusió

- L'interval de predicció per a variables categòriques en concret binàries, no es pot calcular directament, nomès existeix per variables contínues.
- Hem vist que el fet d'afegir un llindar als intervals de confiança per poder fer una segona classificació (*Confiable* o *incert*), fa les prediccions quan són confiables siguin més fiables.
- Amb aquesta fiabilitat hem observat que quan surt Retard (confiable) podríem fiar-nos, ja que ha classificat d'aquesta manera a 11939 de 13131 registres amb retard a la mostra test.

Proposta i qüestionari

