

Interval de predicció del retard en una companyia aèria

Autor: Andy Vacas Garcia — 1600304

Tutor: Antonio Lozano Bages
Treball de final de grau
Grau en estadística aplicada

16/06/2025



Índex

Índex de taules	2
1 Resum	1
2 Introducció i motivació	2
2.1 Objectius	2
3 Context	2
3.1 Polítiques en els retards dels vols als EE.UU.	2
3.2 Història de Southwest Airlines (WN)	3
3.3 Gestió del retards en Southwest Airlines (WN)	3
3.4 Pla d'atenció al client de Southwest Airlines (WN)	3
4 Tècniques	4
4.1 Tècniques de manipulació de dades, visualització i anàlisi exploratòria	4
4.2 Preparació i manipulació de dades	4
4.3 Models predictius (classificació binària)	4
4.3.1 GLM (Regressió Logística)	4
4.3.2 XGBoost (XGBTree)	5
4.3.3 AdaBoost	5
4.3.4 GBM (Gradient Boosting Machines)	6
4.4 Comparació dels models	6
4.5 Mètriques	6
4.6 Interval de confiança i de predicció	7
5 Anàlisi exploratòria de les dades	7
5.1 Dades	7
5.2 Tractament de les dades	8
5.3 Visualització de dades	8
6 Metodologia	13
6.1 Preprocés	13
6.2 Estructura del <i>ensemble</i> i modelització	14
6.3 Fiabilitat	14
6.4 Simulacions	15
7 Resultats	15
7.1 Comparació de models	15
7.2 Fiabilitat del model GLM	15
7.3 Avaluació mitjançant simulacions	17
8 Conclusió i proposta	17
9 Agraïments	18
10 Referències	19
11 Programari	20
11.1 Codi	20

Índex de taules

1	Taula de contingència per els valors reals i les prediccions	6
2	Resum de la primera part de variables	8
3	Resum de la segona part de variables	8

4	Resum de la primera part de variables amb les transformacions fetes	8
5	Resum de la segona part de variables amb les transformacions fetes	9
6	Resum de la primera part de variables filtrades per WN	14
7	Resum de la segona part de variables filtrades per WN	14
8	Casos hipotètics	15
9	Comparació de models	15
10	Classificació segons si hi ha retard o no i segons si es fiable o incert	16
11	Predicció dels casos hipotètics	17

1 Resum

En aquest treball desenvolupem un model predictiu per la variable *Delay*, la qual ens informa si hi ha hagut retard o no en un vol dins de la base de dades Airlines¹. En primer lloc, farem una anàlisi exploratòria de les dades. A continuació, construïrem un bon model per tal de predir si hi haurà retard o no. Dividirem la mostra en dos, una d'entrenament, la qual ens servirà per entrenar els models de classificació binària com GLM, XGBoost i GBM, l'altre, per testar com de bé funciona aquests per separat. Calcularem la *precisió*, la *sensibilitat*, *especificitat* i el *F1-Score* per escollir quin es el model que millor prediu. Seguidament, donarem prediccions a la nostra mostra test i calcularem els intervals de confiança de les prediccions. Posteriorment, classificarem aquestes com fiables o incertes, per tal de donar una major fiabilitat. En últim lloc, crearem alguns casos hipotètics on observarem com es comporta el model, com prediu i si té sentit la classificació que fa en aquests.

¹Veure en: <https://www.kaggle.com/datasets/jimschacko/airlines-dataset-to-predict-a-delay/data>

2 Introducció i motivació

En els últims anys, des del confinament, he observat en el meu entorn un augment de l'afecció de viatjar, de conèixer altres països i altres cultures. Fent ús de diferents transports que no són terrestres ni marítims per arribar a les seves destinacions .

Personalment, des de la pandèmia les meves ganes de viatjar van créixer exponencialment i, en conseqüència, he incrementat el número de viatges amb avió. En alguns d'aquests viatges, el vol s'ha endarrerit o directament no ha sortit, ja sigui per causes meteorològiques o per motius dependents de la pròpia aerolínia. Una experiència personal amb un vol endarrerit va motivar l'interès per estudiar la possibilitat de predir retards aeris.

A l'hora d'escollir el meu treball de final de grau, vaig valorar diferents propostes, però en el moment de documentar-me, no trobava el suficient interès amb els temes proposats. Llavors, vaig buscar bases de dades a Kaggle ², on vaig trobar la base de dades Airlines ³, gràcies a les variables que conté la base, vaig trobar un punt de partida per dur a terme aquest treball, amb un tema que em permet treballar amb dades d'una línia aèria.

La base de dades es compon de 9 variables, éssent Delay la nostra variable d'interès i 539383 casos que, en aquest cas, representen vols:

- id: Variable identificadora dins del dataset.
- Airline: Aerolínia.
- Flight: Número de vol.
- AirportFrom: Aeroport de sortida.
- AirportTo: Aeroport de destí.
- DayOfWeek: Dia de la setmana.
- Time: Durada del vol en minuts.
- Length: Distància (km).
- Delay: 1= Retard, 0= No retard.

2.1 Objectius

- Crear un model per predir si hi haurà retard o no en un vol.
- Crear casos hipotètics per veure la probabilitat de retard.
- Calcular un interval de predicció per cada cas hipotètic.

3 Context

3.1 Polítiques en els retards dels vols als EE.UU.

Les principals aerolínies de EE.UU. tenen diferents compromisos quan es produeixen retards controlables en els vols. Segons el requadre comparatiu ⁴, totes les aerolínies ofereixen la reubicació en altre vol de la mateixa aerolínia sense cost adicional en cas d'un retard significatiu. No obstant, no totes estan disposades a reubicar als passatgers en aerolínies associades sense cost. En relació a les compensacions mentre esperen, la majoria de les aerolínies ofereixen vals o efectiu pel menjar si el passatger ha d'esperar

²Veure en: <https://www.kaggle.com>

³Veure en: <https://www.kaggle.com/datasets/jimschacko/airlines-dataset-to-predict-a-delay/data>

⁴Veure en: <https://www.transportation.gov/airconsumer/airline-customer-service-dashboard>

més de tres hores. Tanmateix, proporcionen allotjament gratuït si la demora obliga a passar la nit, juntament amb transport terrestre gratuït cap a l'hotel en aquests casos.

D'altra banda, cap de les aerolínies ofereix compensació monetària directa quan els passatgers afronten una espera prolongada. Algunes, com Frontier, Hawaiian y JetBlue, poden oferir crèdits de viatge o milles de viatger freqüent en certs casos de retard.

3.2 Història de Southwest Airlines (WN)

Southwest Airlines ⁵ és una companyia aèria nord-americana coneguda per oferir vols nacionals a preus assequibles dins dels Estats Units. Va ser fundada l'any 1971 i esdevé popular per donar un tracte proper i amable amb els clients, una política de tarifes transparents (com ara maletes facturades gratuïtament) i un ambient informal. El seu centre d'operacions principal és a l'aeroport Love Field de Dallas, i el seu símbol borsari és *LUV*, en referència a l'amor i a l'aeroport d'origen, malgrat la seva referència als bitllets d'avió és WN.

3.3 Gestió del retard en Southwest Airlines (WN)

Southwest Airlines estableix diverses opcions pels passatgers afectats per retards significatius en els seus vols, definits amb demores de tres hores o més per vols nacionals i sis o més per vols internacionals. Davant d'aquesta situació, els passatgers poden optar per diferents alternatives:

- **Continuar amb el viatge:** Si el passatger decideix continuar amb el seu itinerari original, no necessita realitzar cap acció. La aerolínia treballa per minimitzar el retard i permet consultar l'estat del vol per la seva web o aplicació mòbil.
- **Canvi de vol:** En casos de retard considerable, Southwest pot reubicar automàticament al passatger en altre vol cap al seu destí. Si la nova reserva no s'ajusta a les seves necessitats, el passatger pot modificar el seu vol sense cost addicional.
- **Cancel·lació amb crèdit de vol:** Si el passatger opta per no viatjar, pot rebre un crèdit de vol o un *Transferable Flight Credit™* (segons el tipus de tarifa adquirida) per futures reserves. Els crèdits generats a partir del 28 de maig de 2025 tindràn data d'expiració, y els escollits pel passatger en casos de retards significatius seràn vàlids per cinc anys.
- **Cancel·lació amb reemborsament al mètode de pagament original:** Si el retard modifica significativament l'itinerari del passatger (sortida o arribada amb diferències superiors a tres hores en vols nacionals i sis hores en internacionals, canvi d'aeroport o augment d'escals), pot sol·licitar el reemborsament total de la seva tarifa. Southwest processa els reemborsaments dins de set dies hàbils, sempre que la reserva es cancel·li almenys 10 minuts abans de l'horari original de sortida.

Aquestes polítiques ⁶ busquen oferir solucions flexibles i garantir la satisfacció dels passatgers davant d'inconvenients operatius.

3.4 Pla d'atenció al client de Southwest Airlines (WN)

El pla d'atenció al client ⁷ de **Southwest Airlines (WN)** ⁸ estableix els compromisos de l'aerolínia amb els seus passatgers en diverses situacions. Alguns dels punts més rellevants inclouen:

- **Tarifes més baixes disponibles:** Southwest ofereix la tarifa més baixa disponible en el moment de la reserva, ja sigui a través del seu lloc web, aplicació mòbil, per telèfon o en els taulells físics.
- **Notificació de retards i cancel·lacions:** Si un vol pateix un retard de 30 minuts o més, la companyia es compromet a notificar als passatgers dins dels següents 30 minuts mitjançant correu electrònic, missatge de text o trucada de veu (segons la preferència seleccionada).

⁵Veure en: <https://www.southwest.com/about-southwest/#aboutUs>

⁶Veure en: <https://support.southwest.com/helpcenter/s/article/options-if-flight-is-delayed>

⁷Veure en: <https://www.southwest.com/assets/pdfs/corporate-commitments/customer-service-plan.pdf?clk=7396032>

⁸Veure en: <https://www.southwest.com>

- **Lliurament d'equipatge a temps:** S'esforçen per retornar l'equipatge als passatgers el més ràpid possible. En cas de retard, intenten lliurar-ho en un termini de 12 hores per a vols nacionals i entre 15 i 30 hores per a vols internacionals.
- **Reemborsaments i canvis de vols:** En cas de cancel·lacions o modificacions a l'itinerari, Southwest ofereix opcions de reemborsament o reubicació en un altre vol sense cost addicional.
- **Atenció al client:** La companyia disposa d'un equip dedicat a garantir el compliment del seu pla de servei i atendre les necessitats dels passatgers.

4 Tècniques

4.1 Tècniques de manipulació de dades, visualització i anàlisi exploratòria

Per poder treballar la base de dades de manera adequada i coherent, hem netejat i transformat les dades:

- Conversió de les columnes a factors.
- Re-codificació de valors de la variable Delay i el convertim a factor.
- Conversió de dies de la setmana a noms.
- Comprovació de valors perduts, fixant-nos en els casos complets.
- Agrupació de la variable Length en intervals per poguer visualitzar d'una forma més clara les distàncies.

4.2 Preparació i manipulació de dades

- **Filtrat de dades:** `dades <- dades[dades$Airline=="WN", ]`.
- **Divisió en conjunts d'entrenament i prova:** `createDataPartition()` de caret.
- **Bootstrapping:** Re-mostra amb reemplaçament per a entrenar múltiples models (`sample(nrow(...), replace = TRUE)`).
- **Mutacions i transformacions:** ús de `dplyr::mutate`, `case_when`, `cut()`, factors amb etiquetes, etc.
- **Conversió de llista a matriu:** `do.call(cbind, ...)`.
- **Agrupació i càlcul de proporcions:** `group_by()`, `count()`, `mutate(porcentaje = ...)`.

4.3 Models predictius (classificació binària)

4.3.1 GLM (Regressió Logística)

La regressió logística, segons [Group, 2025], és un model estadístic molt utilitzat quan la variable de resposta és dicotòmica. En lloc de modelar el resultat directament, com en la regressió lineal, la regressió logística modela la probabilitat que el resultat sigui 1.

Per evitar que el model doni probabilitats fora del rang $[0, 1]$, s'utilitza la funció logit, que transforma probabilitats a la recta real:

$$\text{logit}(x) = \log\left(\frac{x}{1-x}\right)$$

Aquesta funció transforma una probabilitat $x \in (0, 1)$ a un valor entre $-\infty$ i $+\infty$. En el model de regressió logística, aquesta transformació s'expressa com una combinació lineal dels predictors:

$$\text{logit}(p_i) = X_i\beta$$

On:

- $p_i = P(y_i = 1)$ és la probabilitat que la resposta sigui 1 per a l'observació i .
- X_i representa els valors dels predictors per a i .
- β és el vector de coeficients del model.

4.3.2 XGBoost (XGBTree)

XGBoost (eXtreme Gradient Boosting) és una biblioteca optimitzada que implementa el mètode de boosting de gradient, però amb millores de rendiment, eficiència i flexibilitat. Va ser desenvolupada per [Chen and Guestrin, 2016], i s'ha convertit en una de les eines més populars per a problemes de classificació i regressió.

Avantatges principals del XGBoost respecte el boosting tradicional:

- **Regularització:** Afegeix hiperparàmetres de regularització (*lambda* i *alpha*) que ajuden a reduir el sobreajustament. Això el fa més robust que altres implementacions tradicionals de boosting.
- **Detenció anticipada:** Permet aturar l'entrenament automàticament quan el model deixa de millorar després de cert passos. Estalvia temps de càlcul i evita sobreentrenar el model.
- **Processament en paral·lel :** A diferència del boosting tradicional (seqüencial), XGBoost permet entrenament paral·lelitzat.
- **Funcions de pèrdua personalitzades:** Permet definir objectius propis, ajustant-se a casos específics.
- **Entrenament incremental:** Es pot continuar entrenant un model guardat anteriorment, afegint nous arbres sense començar des de zero.
- **Models bàsics diversos:** Encara que per defecte utilitza arbres de decisió, també permet models lineals com a predictors bàsics.

4.3.3 AdaBoost

AdaBoost és un mètode de *boosting* proposat per [Freund and Schapire, 1996]. Esdevé un algoritme d'aprenentatge ensamblat que combina diversos models febles (normalment arbres de decisió poc profunds) per crear un model fort i robust.

Funcionament bàsic:

1. Cada instància de l'entrenament comença amb el mateix pes.
2. Es construeix un model feble (per exemple, un arbre senzill).
3. Es calcula l'error del model i s'ajusten els pesos: Les observacions mal classificades obtenen més pes en el següent model.
4. Es repeteix aquest procés per diversos models.
5. Al final, es combinen tots els models, ponderats segons el seu rendiment (els millors tenen més pes).

Característiques principals

- Dona més pes a les observacions difícils d'encertar.
- Molt útil per problemes de classificació binària.
- Té un alt rendiment amb models simples.
- Sensible al soroll o a dades amb valors atípics (outliers).
- No requereix ajustar massa hiperparàmetres.

4.3.4 GBM (Gradient Boosting Machines)

GBM és una generalització del concepte de *boosting* on s'utilitza un enfocament basat en optimització numèrica mitjançant *descens pel gradient*.

Funcionament bàsic:

1. S'inicialitza el model amb una predicció bàsica (ex: mitjana o log-odds).
2. Es calcula la funció de pèrdua (ex: log loss per classificació).
3. Es construeix un nou model que prediu els residus o gradients de la funció de pèrdua (els errors del model anterior).
4. Aquest model s'afegeix a l'anterior, corregint-lo.
5. El procés es repeteix iterativament fins a obtenir una funció final forta.

Característiques principals:

- Permet utilitzar diferents funcions de pèrdua (log, loss, MSE...).
- És més flexible que AdaBoost.
- Pot regular-se fàcilment amb hiperparàmetres com:
- `n.trees`: nombre d'iteracions o arbres.
- `shrinkage` (*learning rate*): Quant aporta cada nou arbre.
- `interaction.depth`: Profunditat dels arbres.
- Té millor capacitat per generalitzar si es regula bé.
- Menys sensible a outliers que AdaBoost (depèn de la funció de pèrdua).

4.4 Comparació dels models

Els models anteriors ofereixen un equilibri entre interpretabilitat i rendiment.

- El **GLM** destaca per la seva simplicitat i transparència, fet que el fa útil per la interpretació directa.
- **AdaBoost**, malgrat la seva senzillesa, pot assolir bons resultats en dades netes.
- **GBM i XGBoost**, contràriament, ofereixen una capacitat predictiva superior, però requereixen una optimització més acurada i són més costosos computacionalment parlant.

4.5 Mètriques

Un cop obtenim els tres models amb les prediccions, el que fem és avaluar amb l'Accuracy, la Sensibilitat, Especificitat i el F1-score per poder veure quin model és millor dels tres.

	Retard	No retard
Retard	VP	FN
No retard	FP	VN

Taula 1: Taula de contingència per els valors reals i les prediccions

$$Accuracy = \frac{\text{Classificació correcta}}{\text{Totes les classificacions}} = \frac{VP+VN}{VP+FP+VN+FN}$$

$$Sensibilitat = \frac{VP}{VP+FP}$$

$$Especificitat = \frac{VN}{VN+FN}$$

$$F1 - Score = \frac{Accuracy \cdot Sensibilitat}{Accuracy + Sensibilitat}$$

4.6 Intervals de confiança i de predicció

Segons l'article [Botella and Sánchez-Meca, 2024], hi ha diferències entre l'interval de confiança i de predicció:

- **Interval de confiança:** Representa l'incertesa associada amb el tamany de l'efecte mig paramètric en un meta-anàlisi. Es a dir, indica el rang dins del qual és probable que es trobi el valor real del paràmetre amb un cert nivell de confiança.
- **Interval de predicció:** Representa el tamany paramètric probable en qualsevol estadi futur de la mateixa classe que els inclosos en el meta-anàlisi. La seva interpretació és diferent, ja que busca estimar la variabilitat esperada en estudis individuals.

Diferències claus:

- L'interval de confiança es centra a l'estimació de l'efecte mig poblacional.
- L'interval de predicció s'utilitza per anticipar la variabilitat dels efectes en estudis individuals.
- En general, l'interval de predicció sol ser més ampli que el de confiança, ja que incorpora la heterogeneïtat entre estudis.

Segons l'article [Marín, 2025] sobre l'anàlisi de variables categòriques, els intervals de predicció no poden calcular-se per variables categòriques degut a la seva classe i la forma en que s'interpreten en models estadístics.

Raons principals

1. Les variables categòriques no tenen escala contínua:

- Un interval de predicció estima un rang de valors futurs dins d'una distribució contínua.
- Les variables categòriques representen classes o categories discretes (Ex: "Retard", "No retard"), pel que no hi ha valors intermitjos entre elles.

2. No hi ha variabilitat numèrica dins d'una categoria:

- En dades contínues, els intervals de predicció reflecteixen la dispersió dels valors futurs.
- En dades categòriques, cada observació pertany a una categoria específica sense valors intermedis.

3. Alternatives per variables categòriques:

- En lloc d'intervals de predicció s'utilitzen probabilitats de classificació en models, tal com regressió logística o arbres de decisió.
- Es poden calcular intervals de confiança per proporcions de cada categoria en una mostra.

5 Anàlisis exploratòria de les dades

5.1 Dades

Quan obrim les dades trobem que són 539383 vols el temps màxim és de 1439 minuts i la distància màxima és de 655 km, però tenim les variables Airline, AirportFrom, AirportTo i DayOfWeek com a caracter i Delay com a numèrica, totes aquestes les hem de passar a factor per poder treballar bé amb elles.

Amb aquestes transformacions fetes, podem veure que tenim 18 aerolínies, 293 aeroports y per la variable Delay veiem que tenim 240264 vols que han patit un retard i 299119 que no ho han patit.

id	Airline	Flight	AirportFrom	AirportTo
Min. : 1	WN : 94097	16 : 420	ATL : 34449	ATL : 34440
1st Qu.:134847	DL : 60940	5 : 407	ORD : 24822	ORD : 24871
Median :269692	OO : 50254	9 : 401	DFW : 22154	DFW : 22153
Mean :269692	AA : 45656	8 : 396	DEN : 19843	DEN : 19848
3rd Qu.:404538	MQ : 36605	62 : 364	LAX : 16657	LAX : 16656
Max. :539383	US : 34500	371 : 357	IAH : 15821	IAH : 15819
	(Other):217331	(Other):537038	(Other):405637	(Other):405596

Taula 2: Resum de la primera part de variables

DayOfWeek	Time	Length	Delay
1:72769	Min. : 10.0	Min. : 0.0	Retard :240264
2:71340	1st Qu.: 565.0	1st Qu.: 81.0	No_retard:299119
3:89746	Median : 795.0	Median :115.0	
4:91445	Mean : 802.7	Mean :132.2	
5:85248	3rd Qu.:1035.0	3rd Qu.:162.0	
6:58956	Max. :1439.0	Max. :655.0	
7:69879			

Taula 3: Resum de la segona part de variables

5.2 Tractament de les dades

Abans de fer cap visualització, comprovem si hi han valors faltants i no hi trobem cap. No farem canvis en les variables ni descartarem cap cas, perquè al no tenir cap NA, ni cap valor que ens faci sospitar que pugui ser erroni, treballarem amb les dades tal y com estan.

Per fer més facil la visualització de dades, afegim una variable on agrupem les distàncies, de 0 a 200km, de 200 a 400km, de 400 a 600 km i per últim de 600 a 655km, aquest últim ho acotem a 655 perquè és el màxim que hem comentat abans.


id	Airline	Flight	AirportFrom	AirportTo
Min. : 1	WN : 94097	16 : 420	ATL : 34449	ATL : 34440
1st Qu.:134847	DL : 60940	5 : 407	ORD : 24822	ORD : 24871
Median :269692	OO : 50254	9 : 401	DFW : 22154	DFW : 22153
Mean :269692	AA : 45656	8 : 396	DEN : 19843	DEN : 19848
3rd Qu.:404538	MQ : 36605	62 : 364	LAX : 16657	LAX : 16656
Max. :539383	US : 34500	371 : 357	IAH : 15821	IAH : 15819
	(Other):217331	(Other):537038	(Other):405637	(Other):405596


Taula 4: Resum de la primera part de variables amb les transformacions fetes

5.3 Visualització de dades


DayOfWeek	Time	Length	Delay	Length_class
1:72769	Min. : 10.0	Min. : 0.0	Retard :240264	0 a 200 km :465668
2:71340	1st Qu.: 565.0	1st Qu.: 81.0	No_retard:299119	200 a 400 km: 72232
3:89746	Median : 795.0	Median :115.0		400 a 600km : 1415
4:91445	Mean : 802.7	Mean :132.2		600 a 655 km: 68
5:85248	3rd Qu.:1035.0	3rd Qu.:162.0		
6:58956	Max. :1439.0	Max. :655.0		
7:69879				


Taula 5: Resum de la segona part de variables amb les transformacions fetes






Recompte de vols per distància





En les gràfiques observem:

- L'aerolínia amb més registres és la WN que correspon a Southwest Airlines.
- El dia amb més vols registrats és el dijous amb 91445, mentre que el dissabte és el que menys amb 58956.
- Observem que 465668 vols són de 0 a 200km, per tant la gran majoria de la mostra han sigut vols de menys de 200km.
- En la variable Delay trobem que el 44.5% dels vols han patit retard y el 55.5% no.



En aquest últim gràfic, observem com aquells valors, retards i no retards, predominen més en cada aerolínia i, al mateix temps, observem quina aerolínia manté un major registre de vols.

6 Metodolgia

Pel tenir una gran quantitat de dades, hem decidit fer un model per a una aerolínia concreta, per poder treballar millor computacionalment parlant. En el nostre cas, Southwest Airlines (WN) esdevé la que més registres té i, per aquesta raó, hem decidit filtrar per aquesta aerolínia i enfocar-nos en realitzar un model que predigui els retards.

6.1 Preprocés

Com tenim les dades netes, el següent pas que farem és separar la nostra mostra en dades d'entrenament i dades test. Per garantir la reproductibilitat dels resultats, establim una llavor ⁹ abans de dividir la

⁹Per més informació : <https://search.r-project.org/CRAN/refmans/simEd/html/set.seed.html>

id	Airline	Flight	AirportFrom	AirportTo
Min. : 475	WN :94097	28 : 175	LAS : 6360	LAS : 6362
1st Qu.:132929	9E : 0	24 : 156	MDW : 6217	MDW : 6214
Median :266396	AA : 0	759 : 148	PHX : 5098	PHX : 5100
Mean :268362	AS : 0	59 : 142	BWI : 4815	BWI : 4809
3rd Qu.:404185	B6 : 0	1657 : 141	DEN : 4167	DEN : 4170
Max. :538834	CO : 0	30 : 139	HOU : 3711	HOU : 3710
	(Other): 0	(Other):93196	(Other):63729	(Other):63732

Taula 6: Resum de la primera part de variables filtrades per WN

DayOfWeek	Time	Length	Delay	Length_class
Dilluns :12808	Min. : 360.0	Min. : 45.0	Retard :65657	0 a 200 km :84972
Dimarts :12808	1st Qu.: 570.0	1st Qu.: 75.0	No_retard:28440	200 a 400 km: 9125
Dimecres :16118	Median : 795.0	Median : 95.0		400 a 600km : 0
Dijous :16118	Mean : 802.3	Mean :117.5		600 a 655 km: 0
Divendres:14393	3rd Qu.:1030.0	3rd Qu.:150.0		
Dissabte : 9791	Max. :1365.0	Max. :380.0		
Diumenge :12061				

Taula 7: Resum de la segona part de variables filtrades per WN

mostra, utilitzant la llibreria *caret*¹⁰.

6.2 Estructura del *ensemble* i modelització

Per tal de donar una major aleatorietat, seguim una estratègia de *bootstrap ensemble*, on múltiples models són entrenats sobre conjunts de dades seleccionats de forma aleatòria amb reemplaçament de la nostra mostra d'entrenament. Aquesta tècnica ha estat àmpliament estudiada en la literatura com un efectiu per millorar l'estabilitat i precisió dels models predictius ([Breiman, 1996]).

Definim un ensemble de 5 models, seguint la tècnica *bagging* on cada model s'ajusta a una mostra generada per bootstrap ([Good, 2006]). Cada iteració de l'ensemble implica generar una mostra aleatòria amb reemplaçament i ajustar un model optimitzat, on apliquem validació creuada. Cada ensemble estarà compost per cinc models del mateix tipus (GLM, XGBoost o GBM).

Després de l'entrenament, generem prediccions sobre les observacions del test. La combinació de prediccions en un ensemble permet reduir l'error de predicció i millorar la fiabilitat del model ([Dietterich, 2000]). També calculem la mitjana i els intervals de confiança d'aquestes prediccions, fet que ens proporciona una estimació més precisa de les probabilitats de retard i no retard.

Un cop tinguem les prediccions, crearem tres taules de contingència, una per cada ensemble, per tal de poder determinar quin dels tres ensembles és el millor i així evaluar aquests calculant les mètriques escollides; la *precisió*, la *sensibilitat*, la *especificitat* i el *F1-Score*. L'ensemble que millor resultats tingui serà l'escollit per fer la següent part del projecte.

6.3 Fiabilitat

Un cop seleccionem el millor model, el nostre objectiu és observar la fiabilitat de les prediccions d'aquest. El que fem és crear una nova classificació on direm si la predicció és fiable o no, per fer aquesta distinció tenim aquestes casuístiques, les quals aplicarem a cada fila:

- **Retard (confiable):** En el cas que la mitjana de les prediccions sigui superior a 0.5 i l'interval inferior també.

¹⁰Autor: Max Kuhn, Enllaç: <https://cran.r-project.org/web/packages/caret/index.html>

- **No retard (confiable):** En el cas que la mitjana de les prediccions sigui menor a 0.5 i l'interval superior també.
- **Retard (Incert):** En el cas que la mitjana de les prediccions sigui superior a 0.5 i l'interval inferior sigui menor de 0.5.
- **No retard (Incert):** En el cas que la mitjana de les prediccions sigui menor a 0.5 i l'interval superior sigui major de 0.5.

6.4 Simulacions

Per tal de generar les simulacions hem proposat uns casos hipotètics, com el model té en compte algunes de les variables, hem suposat aquestes només, no totes.

AirportFrom	AirportTo	DayOfWeek	Time	Length
LAS	MDW	1	800.00	100.00
PHX	HOU	5	1100.00	150.00
BWI	DEN	7	1500.00	300.00
OAK	SAN	3	100.00	85.00
OAK	SAN	3	90.00	85.00
LAS	MDW	1	215.00	100.00

Taula 8: Casos hipotètics

Aplicarem el mateix procediment que hem utilitzat per identificar el millor model. Inicialment, hem generat cinc models GLM per un ensemble, aplicant *bootstrap* i hem calculat les prediccions dels casos hipotètics per cada model, hem fet la mitjana d'aquestes i hem calculat els seus intervals de confiança. Seguidament, els hem classificat com a confiables o incerts. Per últim, hem juntat les dades en un data frame.

7 Resultats

7.1 Comparació de models

Model	Precisió	Sensibilitat	Especificitat	F1
Regresió logística	0.72	0.93	0.25	0.81
XGBoosting	0.72	0.92	0.28	0.81
Gradient Boosting Machines	0.73	0.92	0.28	0.81


Taula 9: Comparació de models

Atès que els tres models presenten valors similars a les diferents mètriques, hem optat per seguir amb el model GLM pels casos hipotètics i comprovar la seva fiabilitat. Aquesta decisió es basa en el principi de parsimònia, ja que el GLM és el model més simple i interpretable dels tres, a més, permet obtenir resultats fiables amb menor complexitat computacional.

7.2 Fiabilitat del model GLM

Grup	Prediccion	Real	n
Confiable	No_retard	No_retard	1217
Confiable	No_retard	Retard	719
Confiable	Retard	No_retard	3976
Confiable	Retard	Retard	11939
Incert	No_retard	No_retard	228
Incert	No_retard	Retard	221
Incert	Retard	No_retard	267
Incert	Retard	Retard	252

Taula 10: Classificació segons si hi ha retard o no i segons si es confiable o incert



Amb aquests resultats veiem que dintre de la classificació que hem fet tenim que :

- **Confiable:** El 75% dels vols que el model classifica com a *Retard* són realment així. El 62.9% dels vols el model els ha classificat com a *No retard* i són realment així.

- **Incertain:** El 48.6% dels vols s'han classificats com a *Retard* són realment així. El 50.8% s'han classificat com a *No retard* i realment són així.

Amb aquests resultats, observem que, en el cas que classifiquem com *Confiable*, s'han predit bé el 90% dels vols amb retard. En canvi, en el cas dels que no han patit retard, només el 21% els ha predit bé.

7.3 Avaluació mitjançant simulacions

AirportFrom	AirportTo	DayOfWeek	Time	Length	Media	Lower	Upper	Decision
LAS	MDW	1	800.00	100.00	0.78	0.77	0.78	Retard (confiable)
PHX	HOU	5	1100.00	150.00	0.86	0.85	0.86	Retard (confiable)
BWI	DEN	7	1500.00	300.00	0.96	0.96	0.96	Retard (confiable)
OAK	SAN	3	100.00	85.00	0.51	0.50	0.53	Retard (incert)
OAK	SAN	3	90.00	85.00	0.51	0.49	0.52	Retard (incert)
LAS	MDW	1	215.00	100.00	0.45	0.44	0.46	No retard (confiable)

Taula 11: Predicció dels casos hipotètics

En les tres primeres simulacions observem casos hipotètics afegits de manera aleatòria. En les altres tres, l'objectiu ha estat analitzar si, modificant el temps d'arribada, la classificació canvia a *No retard*.

Podem observar en el primer i l'últim cas, hi ha una demora considerable i, quan hem reduït al temps, en l'últim, que hauria de trigar un avió en fer aquest trajecte, la classificació ens ha donat *No retard (confiable)*. Per tant, aquest cas compleix el que nosaltres esperàvem.

8 Conclusió i proposta

Per concloure aquest treball, hem vist que el fet d'afegir un llinar als intervals de confiança per poder fer una segona classificació (*Confiable* o *incert*), fa les prediccions quan són confiables siguin més fiable i, en situacions similars dins de la casuística de la mostra, podríem arribar a anticipar-nos amb una certa confiança. No obstant, amb aquestes dades ens podríem fiar si el vol es classifiqués com a *Retard (confiable)*, en la resta de casos veient els resultats no podríem anticipar-nos tant, ja que amb les dades que tenim el model ha encertat relativament poc el *No retard*.

Hem proposat una metodologia basada en bootstrap per avaluar la variabilitat de les prediccions i, gràcies a això, s'han classificat les prediccions com a *confiables* o *incertes*. Aquest fet permet establir un criteri de confiança adicional que millora la possible pressa de decisió davant un possible retard.

Altrament, respecte als objectius d'aquest treball, hem aconseguit dos dels tres. En primer lloc, hem creat tres models dels quals hem seleccionat un. En segon lloc, hem creat casos hipotètics per tal de veure quina probabilitat proporciona la nostra predicció amb el seu interval de confiança. En l'últim objectiu, hem vist que l'interval de predicció per a variables categòriques en concret binàries, no es pot calcular directament, només existeix per variables contínues. Per tal de suplementar aquest últim objectiu, el procediment aplicat ha esdevingut: calcular les probabilitats de classificació i aquestes les hem etiquetat respecte si es fiable o no la predicció, aquesta segona mesura ens ha servit per donar una fiabilitat a les prediccions i, alhora, hem pogut donar més seguretat a l'hora de confiar en una predicció.

Finalment, com a proposta de millora, es recomana ampliar dades per cada vol amb variables com poden ser l'hora de sortida i l'hora d'arribada, el motiu pel qual ha hagut el retard (per si depèn de l'aerolínia o no), entre altres variables. Seria interessant també fer una anàlisi de regressió per veure quines variables tenen més pes a l'hora que succeeixi un retard. Així doncs, donar un millor servei cap als clients i poder preveure els retards. Tota aquesta informació amb un estudi més profund podria ser especialment útil per la companyia.

9 Agraïments

Desde que vaig decidir el tema del meu treball de final de grau hi ha hagut algunes persones que m'han escoltat, recolzat i aconsellat, vull agraïr al meu tutor Antonio Lozano per acceptar el tema que li vaig proposar des d'un primer moment, va oferir llibertat metodològica i donar-me suport quan li he preguntat els dubtes que m'han anat sorgint, el tutor ha sabut proporcionar-me l'espai necessari per poder treure endavant aquest projecte a la meua manera, sense limitar-me a una manera de treballar concreta. En segon lloc, voldria donar les gràcies a alguns companys de classe, en especial al Manel Rodríguez, l'Andrea Cadiz, al Jose Calatayud i al German Gallego, que en moments de dubtes m'han aportat diferents punts de vista respecte com abordar alguns detalls d'aquest projecte o m'han aconsellats. En últim lloc, a la meua família per haver-me escoltat quan he pogut estar estressat i/o dubtant de tot, en especial al meu germà, el Julen Vacas que, a banda d'això, m'ha aconsellat a l'hora de fer la bibliografia i les citacions bibliogràfiques.

10 Referències

- [Botella and Sánchez-Meca, 2024] Botella, J. and Sánchez-Meca, J. (2024). Meta-análisis: intervalos de confianza e intervalos de predicción. *Anales de Psicología*, 40(2):344–354.
- [Breiman, 1996] Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2):123–140.
- [Chen and Guestrin, 2016] Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, New York, NY, USA. ACM.
- [Dietterich, 2000] Dietterich, T. G. (2000). Ensemble methods in machine learning. In *International Workshop on Multiple Classifier Systems*, pages 1–15, Berlin, Heidelberg. Springer.
- [Freund and Schapire, 1996] Freund, Y. and Schapire, R. E. (1996). Experiments with a new boosting algorithm. *Proceedings of the Thirteenth International Conference on Machine Learning*, pages 148–156.
- [Good, 2006] Good, P. I. (2006). *Resampling Methods: A Practical Guide to Data Analysis*. Birkhäuser, New York, 3rd edition.
- [Group, 2025] Group, I. B. R. (2025). Regressió logística. https://isglobal-brge.github.io/Aprendizaje_Automatico_1/regresi%C3%B3n-log%C3%ADstica.html.
- [Marín, 2025] Marín, J. M. (2025). Análisis de variables categóricas. *Guía SPSS*.

11 Programari

Hem de mencionar que aquest treball ha estat realitzat utilitzant les següents llibreries de R: `knitr`, `highlight`, `xtable`, `here`, `dplyr`, `mice`, `gridExtra`, `ggplot2`, `formatR`, `skimr`, `kableExtra`, `multcomp`, `utils`, `MASS`, `moments`, `AER`, `pscl`, `tidyverse`, `caret`, `purrr` i `xtable`. Aquest document ha sigut generat des d'un arxiu Sweave (.Rnw).

11.1 Codi

```
> direction<-here()
> dir_data<-here(direction,"data")
> dir_data_clean<-here(dir_data,"data_clean")
> dir_data_raw<-here(dir_data,"data_raw")
> scripts_dir<-here("scripts")
>
> report_dir<-here("report")
> graph_report_dir<-here(report_dir,"graph")
>
> Airlines<-read.csv(here(dir_data_raw,"Airlines.csv"))
>
> s_airlines<-summary(Airlines)
>
> dades<-Airlines
> dades<-dades %>%
+   mutate(across(c(DayOfWeek,Airline,AirportFrom,AirportTo,Flight),as.factor))
>
> #Asumim que 1="Retard" i 0= "No Retard"
> dades <- dades %>%
+   mutate(Delay = factor(Delay, levels = c(1, 0), labels = c("Retard", "No_retard")))
>
>
> glimpse(dades)
> s_airlines<-summary(dades)
> #Mirem si hi ha dades faltants
> #unique(dades$id)
> cc.index <- complete.cases(dades)
> db <- dades[cc.index,]
> ifelse(length(db$id)==length(dades$id), print("No hi ha dades faltants."), print("Sí hi ha dades faltants. "))
>
> #Posem en grups la variable length:
> dades$Length_class<- cut(dades$Length,
+   breaks = c(min(dades$Length), 200, 400,600, max(dades$Length)),
+   labels = c("0 a 200 km ", "200 a 400 km","400 a 600km", "600 a 655 km"),
+   include.lowest = TRUE)
>
>
> s_dades<-summary(dades)
>
> #Guardem les dades
> save(dades,file = here(dir_data_clean,"Airlines.RData"))
>
> #Posem els noms dels dies de la setmana, per fer la descriptiva
> dades <- dades %>%
+   mutate(DayOfWeek = factor(DayOfWeek, levels = c(1, 2,3,4,5,6,7), labels = c("Dilluns","Dimarts","Dimecres","Dijous","Div")
>
>
> delay_plot<-ggplot(data = dades, aes(x = Delay, y = ..count.., fill = Delay)) +
+   geom_bar() +
+   geom_text(stat = "count", aes(label = ..count..), vjust = -0.5) +
+   scale_fill_manual(values = c("gray50", "orangered2")) +
+   labs(title = "Retards") +
+   theme_bw() +
+   theme(legend.position = "bottom")
>
> # Calculem percentatges
> delay_counts <- dades %>%
```

```

+   count(Delay) %>%
+   mutate(percentage = round(n / sum(n) * 100, 1))
>
> # Creem gràfic amb percentatges
> delay_plot <- ggplot(delay_counts, aes(x = Delay, y = percentage, fill = Delay)) +
+   geom_bar(stat = "identity") +
+   geom_text(aes(label = paste0(percentage, "%"), vjust = -0.5) +
+   scale_fill_manual(values = c("gray50", "orangered2")) +
+   labs(title = "Percentatge de retards i no retards", y = "Percentatge") +
+   theme_bw() +
+   theme(legend.position = "bottom")
>
>
> #Tabla de freqüències
> table(dades$Delay)
> prop.table(table(dades$Delay)) %>% round(digits = 2)
>
> retràs
> n_observaciones <- nrow(dades)
> predicciones <- rep(x = "No retard", n_observaciones)
> mean(predicciones == dades$Delay) * 100
>
> skimr::skim(dades)
>
>
>
>
>
> # Creem gràfics per fer l'exploració
> p1 <- ggplot(dades, aes(x = Airline)) +
+   geom_bar(fill = "steelblue") +
+   geom_text(stat = 'count', aes(label = ..count..), vjust = -0.5) +
+   ggtitle("Recompte de vols per aerolínia")
>
> p2 <- ggplot(dades, aes(x = DayOfWeek)) +
+   geom_bar(fill = "forestgreen") +
+   geom_text(stat = 'count', aes(label = ..count..), vjust = -0.5) +
+   ggtitle("Recompte de vols per dia de la semana")
>
> p3 <- ggplot(dades, aes(x = Length_class)) +
+   geom_bar(fill = "tomato") +
+   geom_text(stat = 'count', aes(label = ..count..), vjust = -0.5) +
+   ggtitle("Recompte de vols per distància")
>
> p4 <- ggplot(dades, aes(x = Delay)) +
+   geom_bar(fill = c("gray50", "orangered2")) +
+   geom_text(stat = 'count', aes(label = ..count..), vjust = -0.5) +
+   ggtitle("Recompte de vols amb retard i sense")
>
>
> # Mostrem els gràfics en una quadre de 2x2
> descriptive1<-grid.arrange(p1, p2, p3, p4, nrow = 2)
> save(descriptive1,file=here(graph_report_dir,"descriptive1.png"))
>
> p5<-ggplot(data = dades, aes(x = Airline, y = ..count.., fill = Delay)) +
+   geom_bar() +
+   scale_fill_manual(values = c("gray50", "orangered2")) +
+   labs(title = "Retard i no retard per cada aerlínia") +
+   theme_bw() +
+   theme(legend.position = "bottom")
>
> ggplot(data = dades, aes(x = DayOfWeek, y = ..count.., fill = Delay)) +
+   geom_bar() +
+   scale_fill_manual(values = c("gray50", "orangered2")) +
+   labs(title = "Day of week") +
+   theme_bw() +
+   theme(legend.position = "bottom")
>
> ggplot(data = dades, aes(x = Airline, y = ..count.., fill =Length_class )) +

```



```

+ geom_bar() +
+ #scale_fill_manual(values = c("gray50", "orangered2")) +
+ labs(title = "Airline") +
+ theme_bw() +
+ theme(legend.position = "bottom")

> #####
> #Primer filtrem per WN ja que es la aerolínia escollida
> datos<-dades
> datos<-datos[datos$Airline=="WN" ,]
> s_datos<-summary(datos)
> #####
>
> #Dividim de aleatòriament la mostra en dos, train i test.
> set.seed(123)
>
> train <- createDataPartition(y = datos$Delay, p = 0.8, list = FALSE, times = 1)
> datos_entrenamiento <- datos[train, ]
> nueva_instancia <- datos[-train, ]
>
>
>
>
> # Definim el nombre de models en l'ensemble
> num_modelos <- 5
> predicciones <- numeric(num_modelos)
>
>
>
> # Creem els dataframe on guardarem les dades
> comparacio2<-data.frame(Real=nueva_instancia$Delay,
+                         Prediccion=c(1:length(nueva_instancia$Delay)),
+                         "IP Inferior"=c(1:length(nueva_instancia$Delay)),
+                         "IP Superior"=c(1:length(nueva_instancia$Delay)))
>
> predicciones<-data.frame("Modelo 1"=c(1:length(nueva_instancia$Delay)),
+                          "Modelo 2"=c(1:length(nueva_instancia$Delay)),
+                          "Modelo 3"=c(1:length(nueva_instancia$Delay)),
+                          "Modelo 4"=c(1:length(nueva_instancia$Delay)),
+                          "Modelo 5"=c(1:length(nueva_instancia$Delay)))
>
>
>
> #####
>
> #GLM
>
> num_modelos<-5
> ctrl <- trainControl(method = "cv", classProbs = TRUE)
> entrenar_y_predecir_glm <- function(i) {
+   muestra <- datos_entrenamiento[sample(nrow(datos_entrenamiento), replace = TRUE), ]
+
+   modelo_glm <- train(Delay ~ AirportFrom+ AirportTo + DayOfWeek + Time + Length,
+                       data = muestra,
+                       method = "glm",
+                       family = binomial,
+                       trControl = ctrl)
+
+   predict(modelo_glm, nueva_instancia[, -9], type = "prob")[, "Retard"]
+ }
>
> # Apliquem la funció a num_models iteracions utilitzant map
> predicciones_lista_glm <- map(1:num_modelos, entrenar_y_predecir_glm)
>
> # Convertim de llista a matriu per facilitar càlculs
> predicciones_glm <- do.call(cbind, predicciones_lista_glm)
>

```

```

> # Calculem la mitjana de les prediccions per files i els seus intervals de confiança
> media_glm <- map_dbl(1:nrow(predicciones_glm), ~ mean(predicciones_glm[.x, ]))
> lower_glm <- map_dbl(1:nrow(predicciones_glm), ~ quantile(predicciones_glm[.x, ], 0.05))
> upper_glm <- map_dbl(1:nrow(predicciones_glm), ~ quantile(predicciones_glm[.x, ], 0.95))
>
> # Combinem tot en un data frame final
> comparacio2_glm <- tibble(
+   Real = as.character(nueva_instancia$Delay),
+   Media = media_glm,
+   Lower = lower_glm,
+   Upper = upper_glm
+ )
>
> #Classifiquem les prediccions
> y_pred_glm <- ifelse(comparacio2_glm$Media > 0.5, 1, 0)
> y_pred_glm <- factor(y_pred_glm, levels = c(1, 0), labels = c("Retard", "No_retard"))
>
> #Creem la taula de contingència
> cm_glm <- table(comparacio2_glm$Real, y_pred_glm)
>
> # Calculem les mètriques
> # Precisió
> precision_glm <- (cm_glm["Retard", "Retard"]+ cm_glm["No_retard", "No_retard"]) / sum(cm_glm)
> # Sensibilitat
> sensibility_glm <- cm_glm["Retard", "Retard"] / sum(cm_glm["Retard", ])
> # Especificitat
> especificity_glm <- cm_glm["No_retard", "No_retard"] / sum(cm_glm["No_retard", ])
> #F1-Score
> f1_glm<-2*(precision_glm*sensibility_glm)/(precision_glm+sensibility_glm)
>
> #####
> #XGBTree
> num_modelos<-5
> ctrl <- trainControl(method = "cv", classProbs = TRUE)
>
>
> # Definim la graella d'hiperparàmetres per a xgboost
> grid_xgb <- expand.grid(
+   nrounds = 50,
+   max_depth = 3,
+   eta = 0.1,
+   gamma = 0,
+   colsample_bytree = 0.8,
+   min_child_weight = 1,
+   subsample = 0.8
+ )
>
> # Funció per entrenar i predeir amb XGBoost
> entrenar_y_predecir_xgb <- function(i) {
+   muestra <- datos_entrenamiento[sample(nrow(datos_entrenamiento), replace = TRUE), ]
+
+   modelo_xgb <- train(
+     Delay ~ AirportFrom+ AirportTo + DayOfWeek + Time + Length,
+     data = muestra,
+     method = "xgbTree",
+     trControl = ctrl,
+     tuneGrid = grid_xgb,
+     verbosity = 0
+   )
+
+   predict(modelo_xgb, nueva_instancia[, -9], type = "prob")[, "Retard"]
+ }
>
> # Executem els models bootstrap amb map
> predicciones_lista_xgb <- map(1:num_modelos, entrenar_y_predecir_xgb)
>
> # Convertim la llista a matriu
> predicciones_xgb <- do.call(cbind, predicciones_lista_xgb)
>
> # Calculem la mitjana de les prediccions per files i els seus intervals de confiança

```

```

> media_xgb <- map_dbl(1:nrow(predicciones_xgb), ~ mean(predicciones_xgb[.x, ]))
> lower_xgb <- map_dbl(1:nrow(predicciones_xgb), ~ quantile(predicciones_xgb[.x, ], 0.05))
> upper_xgb <- map_dbl(1:nrow(predicciones_xgb), ~ quantile(predicciones_xgb[.x, ], 0.95))
>
> # Agrupem els resultats
> comparacio2_xgb <- tibble(
+   Real = as.character(nueva_instancia$Delay),
+   Media = media_xgb,
+   Lower = lower_xgb,
+   Upper = upper_xgb
+ )
>
> # Classificació binària amb un umbral de 0.5
> y_pred_xgb <- ifelse(comparacio2_xgb$Media > 0.5, 1, 0)
> y_pred_xgb <- factor(y_pred_xgb, levels = c(1, 0), labels = c("Retard", "No_retard"))
>
> # Matriu de confusió
> cm_xgb <- table(comparacio2_xgb$Real, y_pred_xgb)
>
> # Calculem les mètriques
> precision_xgb <- (cm_xgb["Retard", "Retard"] + cm_xgb["No_retard", "No_retard"]) / sum(cm_xgb)
> sensibility_xgb <- cm_xgb["Retard", "Retard"] / sum(cm_xgb["Retard", ])
> especificity_xgb <- cm_xgb["No_retard", "No_retard"] / sum(cm_xgb["No_retard", ])
> f1_xgb <- 2*(precision_xgb*sensibility_xgb)/(precision_xgb+sensibility_xgb)
>
> #####
> #GBM
> num_modelos <- 5
> ctrl <- trainControl(method = "cv", classProbs = TRUE)
> grid <- data.frame(
+   n.trees = 100,
+   interaction.depth = 3,
+   shrinkage = 0.1,
+   n.minobsinnode = 10
+ )
> entrenar_y_predecir_gbm <- function(i) {
+   muestra <- datos_entrenamiento[sample(nrow(datos_entrenamiento), replace = TRUE), ]
+
+   modelo_gbm <- caret::train(Delay ~ AirportFrom+ AirportTo + DayOfWeek + Time + Length,
+                               data = muestra,
+                               method = "gbm",
+                               trControl = ctrl,
+                               tuneGrid=grid,
+                               distribution = "adaboost")
+
+   predict(modelo_gbm, nueva_instancia[, -9], type = "prob")[, "Retard"]
+ }
>
> # Aplicar la función a num_modelos iteraciones usando map
> predicciones_lista_gbm <- map(1:num_modelos, entrenar_y_predecir_gbm)
>
> # Convertir lista a matriz para facilitar cálculos
> predicciones_gbm <- do.call(cbind, predicciones_lista_gbm)
>
> # Calcular estadísticos resumen por fila
> media_gbm <- map_dbl(1:nrow(predicciones_gbm), ~ mean(predicciones_gbm[.x, ]))
> lower_gbm <- map_dbl(1:nrow(predicciones_gbm), ~ quantile(predicciones_gbm[.x, ], 0.05))
> upper_gbm <- map_dbl(1:nrow(predicciones_gbm), ~ quantile(predicciones_gbm[.x, ], 0.95))
>
> comparacio2_gbm <- tibble(
+   Real = as.character(nueva_instancia$Delay),
+   Media = media_gbm,
+   Lower = lower_gbm,
+   Upper = upper_gbm
+ )
>
> comparacio2_gbm$Media

```

```

> y_pred_gbm <- ifelse(comparacio2_gbm$Media > 0.5, 1, 0)
> y_pred_gbm <- factor(y_pred_gbm, levels = c(1, 0), labels = c("Retard", "No_retard"))
>
>
> cm_gbm <- table(comparacio2_gbm$Real, y_pred_gbm)
>
> # Calculem mètriques
> precision_gbm <- (cm_gbm["Retard", "Retard"] + cm_gbm["No_retard", "No_retard"]) / sum(cm_gbm)
> sensibility_gbm <- cm_gbm["Retard", "Retard"] / sum(cm_gbm["Retard", ])
> especificity_gbm <- cm_gbm["No_retard", "No_retard"] / sum(cm_gbm["No_retard", ])
> f1_gbm <- 2 * (precision_gbm * sensibility_gbm) / (precision_gbm + sensibility_gbm)
>
> #####
>
> #Indicadors
>
> indicadores <- data.frame("Model" = c("Regresió logística", "XGBoosting", "Gradient Boosting Machines"),
+                           "Precisió" = c(precision_glm, precision_xgb, precision_gbm),
+                           "Sensibilitat" = c(sensibility_glm, sensibility_xgb, sensibility_gbm),
+                           "Especificitat" = c(especificity_glm, especificity_xgb, especificity_gbm),
+                           "F1" = c(f1_glm, f1_xgb, f1_gbm))
> #####
>
> #Fiabilitat
> comparacio2_glm <- comparacio2_glm %>%
+   mutate(
+     Decision = case_when(
+       Media > 0.5 & Lower > 0.5 ~ "Retard (confiable)",
+       Media < 0.5 & Upper < 0.5 ~ "No_retard (confiable)",
+       Media < 0.5 & Upper > 0.5 ~ "No_retard (incert)",
+       TRUE ~ "Retard (incert)"
+     )
+   )
>
> comparacio2_glm <- comparacio2_glm %>%
+   mutate(
+     Prediccion = case_when(
+       grepl("Retard", Decision) ~ "Retard",
+       TRUE ~ "No_retard"
+     ),
+     Grupo = case_when(
+       grepl("confiable", Decision) ~ "Confiable",
+       TRUE ~ "Incert"
+     )
+   )
>
> data_decision_real_sin_porcentage <- comparacio2_glm %>%
+   count(Grupo, Prediccion, Real) %>%
+   group_by(Grupo, Prediccion) %>%
+   ungroup()
>
> data_decision_real <- comparacio2_glm %>%
+   count(Grupo, Prediccion, Real) %>%
+   group_by(Grupo, Prediccion) %>%
+   mutate(
+     porcentaje = round(100 * n / sum(n), 1),
+     etiqueta = paste0(porcentaje, "%")
+   ) %>%
+   ungroup()
>
>
> b1 <- ggplot(data_decision_real, aes(x = Prediccion, y = porcentaje, fill = Real)) +
+   geom_col(position = position_dodge(width = 0.9)) +
+   facet_wrap(~Grupo) +
+   geom_text(aes(label = etiqueta,
+                 position = position_dodge(width = 0.9),
+                 vjust = -0.5, size = 3) +
+   labs(title = "Comparació entre predicció del model i realitat per fiabilitat",
+        y = "Percentatge (%)",

```

```

+       x = "Predicció del model") +
+       scale_y_continuous(expand = c(0, 0), limits = c(0, 100)) + #limits = c(0, 100))
+       theme_minimal()

> # 1. Paquets necessaris
>
> #library(caret)
> #library(tidyverse)
>
> # 2. Paràmetres
>
> set.seed(123)
> num_models <- 5
> ctrl <- trainControl(method = "cv", classProbs = TRUE)
> datos$DayOfWeek<-as.factor(as.numeric(datos$DayOfWeek))
>
>
> # 3. Casos hipotètics
>
> casos_hipotetics <- tibble(
+   AirportFrom = factor(c("LAS", "PHX", "BWI", "OAK", "OAK", "LAS"), levels = levels(datos$AirportFrom)),
+   AirportTo   = factor(c("MDW", "HOU", "DEN", "SAN", "SAN", "MDW"), levels = levels(datos$AirportTo)),
+   DayOfWeek   = factor(c(1, 5, 7, 3, 3, 1), levels = levels(datos$DayOfWeek)),
+   Time        = c(800, 1100, 1500, 100, 90, 215),
+   Length      = c(100, 150, 300, 85, 85, 100)
+ )
> casos_hipotetics_df<-data.frame(casos_hipotetics)
>
> # 4. Funció per simular prediccions
>
> simular_prob_retard <- function(casos, dades_entrenament) {
+   probs <- replicate(num_models, {
+     mostra <- dades_entrenament[sample(nrow(dades_entrenament), replace = TRUE), ]
+
+     model <- train(
+       Delay ~ AirportFrom + AirportTo + DayOfWeek + Time + Length,
+       data = mostra,
+       method = "glm",
+       family = binomial,
+       trControl = ctrl
+     )
+
+     predict(model, casos, type = "prob")[, "Retard"]
+   })
+
+   tibble(
+     Media = rowMeans(probs),
+     Lower = apply(probs, 1, quantile, probs = 0.05),
+     Upper = apply(probs, 1, quantile, probs = 0.95)
+   )
+ }
>
>
> # 5. Executem la simulació
>
> resultats_simulacio <- simular_prob_retard(casos_hipotetics, datos)
>
>
> # 6. Avaluem la fiabilitat
>
> resultats_simulacio <- resultats_simulacio %>%
+   mutate(
+     Decision = case_when(
+       Media > 0.5 & Lower > 0.5 ~ "Retard (confiable)",
+       Media < 0.5 & Upper < 0.5 ~ "No_retard (confiable)",
+       Media < 0.5 & Upper > 0.5 ~ "No_retard (incert)",
+       TRUE ~ "Retard (incert)"
+     )
+   )

```

```
+ )  
>  
>  
> # 7. Guardem les simulacions com a data frame  
>  
> casos_resultats_simulacio <- bind_cols(casos_hipotetics, resultats_simulacio)  
> casos_resultats_simulacio_df<-data.frame(casos_resultats_simulacio)
```